



Predicción de Cancelación de Reservas Hoteleras

Un reto de clasificación con impacto directo en revenue management

1. Contexto de negocio

Escenario

Trabajas como data scientist en una cadena hotelera con dos propiedades en Portugal. El equipo de Revenue Management te pide un modelo que identifique, en el momento de la reserva, qué clientes tienen alta probabilidad de cancelar.

El objetivo es activar acciones preventivas: ofrecer upgrades con descuento, solicitar depósito no reembolsable de forma selectiva, o ajustar la política de overbooking para minimizar habitaciones vacías de última hora.

Una cancelación no detectada implica una habitación vacía a precio de coste. Una acción preventiva innecesaria puede molestar a un cliente fiel. Tu modelo debe equilibrar ambos errores.

2. Dataset

Hotel Booking Demand — Antonio, Almeida & Nunes (2019)

- **Kaggle: [jessemostipak/hotel-booking-demand](#) · Licencia CC0** Fuente:
- **~119.000 reservas · 2 hoteles · julio 2015 – agosto 2017** Volumen:
- **is_canceled (1 = cancelada, ~37% de los registros)** Target:



Variables principales disponibles:

Variable	Tipo	Descripción
<i>hotel</i>	Categórica	City Hotel o Resort Hotel
<i>lead_time</i>	Numérica	Días entre reserva y check-in
<i>arrival_date_*</i>	Fecha	Año, mes, semana, día de llegada
<i>stays_in_*_nights</i>	Numérica	Noches entre semana / fin de semana
<i>adults / children / babies</i>	Numérica	Composición del grupo
<i>meal</i>	Categórica	Régimen alimenticio (BB, HB, FB...)
<i>country</i>	Categórica	País de origen del cliente
<i>market_segment</i>	Categórica	Canal de captación (Direct, TA/TO...)
<i>is_repeated_guest</i>	Binaria	Cliente repetidor
<i>previous_cancellations</i>	Numérica	Cancelaciones anteriores del cliente
<i>adr</i>	Numérica	Average Daily Rate (€ por noche)
<i>total_of_special_requests</i>	Numérica	Número de peticiones especiales
<i>is_canceled</i>	Binaria (target)	1 = cancelada, 0 = no cancelada

Atención a posibles Data Leakage — variables a excluir obligatoriamente

Ten en cuenta que hay variables que revelan directamente el resultado de la reserva. Incluirlas en el modelo sería fuga de información (data leakage). Su uso implica penalización automática en la nota.

3. Proceso esperado

3.1 EDA y comprensión del negocio

- Distribución de cancelaciones por hotel, mes y canal de distribución
- Relación entre *lead_time* y tasa de cancelación
- Comparación de ADR medio entre reservas canceladas y no canceladas
- Al menos una conclusión accionable por sección del EDA

3.2 Feature engineering

Se espera que construyas variables nuevas a partir de las existentes.

Ejemplo:



- `total_guests = adults + children + babies`

Cada variable nueva debe ir acompañada de una justificación de negocio de una o dos frases.

3.3 Train y Test

Regla de partición

Ten en cuenta para la partición la componente temporal del set de datos.

3.4 Modelado

- Modelo baseline: Regresión Logística interpretable como referencia
- Probar otros modelos si superan baseline
- Optimización de hiperparámetros: GridSearch, RandomSearch, Optuna
- Gestión del desbalanceo

3.5 Evaluación orientada a negocio

- Reportar AUC-ROC, F1-score, Precision y Recall sobre el conjunto de test

3.6 Interpretabilidad

- SHAP summary plot: importancia global de variables
- SHAP waterfall plot para al menos dos reservas concretas
- Conclusión de negocio: ¿qué perfil de reserva tiene mayor riesgo y por qué?

4. Entregables

- Jupyter notebook:
 1. Un único Jupyter Notebook limpio y reproducible (ejecutable de arriba abajo sin errores)
 2. Con comentarios en el código que expliquen las decisiones tomadas
 3. Una celda de conclusiones al final con los hallazgos de negocio más relevantes
 4. Formato de entrega: notebook .ipynb
- Presentación: El ejercicio se presentará durante la clase en formato ppt o similar. Para aquellos que no puedan presentarlo ese día tendréis que entregar un video con la explicación.



5. Criterios de evaluación

Entregable	Criterio principal	Peso
Notebook	EDA, Insights de negocios, limpieza de datos, ,modelos, rendimiento del modelo, optimización, interpretabilidad.	60%
Presentación	Introducción del problema de negocio que tratamos de resolver, insights de negocio, modelo ganador, variables más importantes, propuesta de negocio (acción que planteamos, cómo usar el modelo, próximos pasos, que otros análisis, estudios, modelos proponemos hacer)	40%

La nota máxima requiere que todas las decisiones técnicas estén justificadas desde la perspectiva de negocio, no solo desde la metodológica.

6. Referencias y recursos

- Antonio, N., Almeida, A. & Nunes, L. (2019). Hotel booking demand datasets. Data in Brief, 22, 41–49.
- Dataset en Kaggle: kaggle.com/datasets/jessemostipak/hotel-booking-demand.